

# 1. 线性回归. → 回归任务

学习  $f(x_i) = wx + b$  使得  $f(x_i) \approx y_i$  用均方误差最小化来求  $w$  和  $b$

$$\frac{\partial E(w, b)}{\partial w} = 2(w \sum x_i^2 - \sum (y_i - b)x_i) \Rightarrow w = \frac{\sum y_i (x_i - \bar{x})}{\sum x_i^2 - n(\bar{x})^2}$$

$$\frac{\partial E(w, b)}{\partial b} = 2(mb - \sum (y_i - wx_i)) \Rightarrow b = \frac{1}{n} \sum (y_i - wx_i)$$

closed-form 的解

更一般来说  $\frac{\partial E}{\partial w} = 2X^T(Xw - y)$   
 $\hat{w} = (X^T X)^{-1} X^T y$

例:

$$y = g^{-1}(w^T x + b) \text{ 广义线性模型}$$

$$g(y) = w^T x + b$$

$$ln y = w^T x + b$$

$$y = e^{w^T x + b}$$

## 2. logistic regression

$$\ln \frac{y}{1-y} = w^T x + b$$

$\frac{y}{1-y}$  称为 odds  $y$  表示视样本  $x$  为正样本的几率

用极大似然法估计参数

优点: 无需假设数据分布  
 可得到预测概率  
 sigmoid  $\Rightarrow$  任意所可导

## 3. Linear Discriminant Analysis LDA 线性判别分析 → 监督降维技术

将样本投影到直线上 使同类样本投影点尽可能接近

def: 两类样本的中心在直线上的投影  $w^T \mu_0, w^T \mu_1$ ; 两类样本协方差  $w^T \Sigma_0 w, w^T \Sigma_1 w$

欲使同类样本接近 异类样本远离  $w^T \Sigma_0 w + w^T \Sigma_1 w \downarrow \parallel w^T \mu_0 - w^T \mu_1 \parallel_2^2$  尽可能大  $\Rightarrow J = \frac{\parallel w^T \mu_0 - w^T \mu_1 \parallel_2^2}{w^T \Sigma_0 w + w^T \Sigma_1 w}$

$$= \frac{w^T (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T w}{w^T (\Sigma_0 + \Sigma_1) w}$$

$$= \frac{w^T S_b w}{w^T S_w w} \Rightarrow \text{LDA 最大化目标}$$

类内散度矩阵  $S_w = \Sigma_0 + \Sigma_1 = \sum_{x \in X_0} (x - \mu_0)(x - \mu_0)^T + \sum_{x \in X_1} (x - \mu_1)(x - \mu_1)^T$

$$S_b = (\mu_0 - \mu_1)(\mu_0 - \mu_1)^T$$

$$\Rightarrow \min -w^T S_b w$$

s.t.  $w^T S_w w = 1$

$$\Rightarrow S_b w = \lambda S_w w = \lambda (\mu_0 - \mu_1)$$

$$w = S_b^{-1} (\mu_0 - \mu_1)$$

多分类学习

$$\begin{cases} D_0 D \\ D_0 R \\ M_0 M \end{cases} \begin{matrix} \nearrow \\ \nearrow \\ \nearrow \end{matrix} \begin{matrix} N(N-1)/2 \text{ 两两配对} \\ \text{特例} \end{matrix}$$

类别不平衡

理论解决方法:  $\frac{y}{1-y} > 1$  视为正例  $\Rightarrow \frac{y}{1-y} > \frac{m^+}{m^-}$  视为正例. 再缩放 代价敏感学习

实际操作方法:

- 欠采样: 去除反例 Easy Ensemble
- 过采样: 增加正例 SMOTE
- 阈值移动 threshold-moving